

2020~21 겨울특강

# 텐서플로 기반 딥러닝

동양미래대학교 컴퓨터정보공학과 강환수 교수

# CNN(합성곱) 개요

# 이미지 분류 경진대회 ILSVRC

- **ILSVRC(ImageNet Large Scale Visual Recognition Challenge)**
  - 이미지 인식(image recognition) 경진대회
    - ImageNet DB 중 일부를 사용해 이미지 범주를 분류
      - <http://image-net.org/>
  - 대용량의 이미지셋을 주고 이미지 분류 알고리즘의 성능을 평가하는 대회
    - 140만개 이상의 이미지, 1000개의 분류
  - 2010년에 시작되어, 2017년 종료
- **2010년, 2011년에 우승을 차지한 알고리즘**
  - 얇은 구조(shallow architecture)
- **2012년 CNN 기반 딥러닝 알고리즘 AlexNet이 우승**
  - 깊은 구조(deep architecture), 약 26%였던 인식 오류률을 16%까지 개선
- **2017년 종료**
  - 2015년
    - 사람의 정확도라고 알려진 5%를 추월
  - 2017년
    - SENet의 경우 2.3%로 사람의 인식 에러률의 절반도 안됨

# ILSVRC 에러율

## 우승 알고리즘의 분류 에러율(%)





그림1. ILSVRC 대회 역대 우승 알고리즘들과 인식 에러율.

# 딥러닝 깊이의 증가




(slide from Kaiming He's recent presentation)

# AlexNet 구조

## AlexNet의 기본구조

- LeNet-5와 크게 다르지 않으며
- 2개의 GPU로 병렬연산을 수행하기 위해서 병렬적인 구조로 설계



# 이미지 특징 추출 알고리즘

- **Feature extraction**

- 필터(커널)를 사용해 이미지의 주요 특징을 추출


- **외곽선 검출 알고리즘**

0	0	0
-1	1	0
0	0	0

(a) 수직 에지 검출 마스크

0	-1	0
0	1	0
0	0	0

(b) 수평 에지 검출 마스크



# CNN(Convolutional Neural Network) 개요

## • CNN

- 이미지의 공간 정보를 유지한 상태로 학습이 가능한 모델

- 특징 추출기 + 분류기 구성

## • 일반 Dense() 층과 비교

- Fully Connected Neural Network와 비교하여 다음과 같은 차별성

- 각 레이어의 입출력 데이터의 형상 유지

- 이미지의 공간 정보를 유지하면서 인접 이미지와의 특징을 효과적으로 인식

- 복수의 필터로 이미지의 특징 추출 및 학습

- 추출한 이미지의 특징을 모으고 강화하는 Pooling 레이어

- 일반 신경망과 비교하여 학습 패러미터가 매우 적음

- 필터를 공유 패러미터로 사용하기 때문

2018 Turing Award for deep learning

most prestigious technical award, is given for major contributions of lasting importance to computing.



Jeffrey Hinton



Yoshua Bengio



Yann LeCun

## • LeCun 1998년

- LeNet이라는 Network를 1998년에 제안


- 얀 르쿤(Yann Lecun) 연구팀

- 이것이 최초의 CNN



# CNN은 컨볼루션 층과 풀링 층, 분류기로 구성




- **Feature Extractor(특징 추출기) + Classifier(분류기)**
  - 이미지의 특징을 추출하는 부분과 클래스를 분류하는 부분으로 나눔
- **특징 추출기:**
  - 자동으로 특징을 추출하는 필터를 생성하는 것이 목적
    - Convolution Layer와 Pooling Layer를 여러 겹 쌓는 형태로 구성
    - Convolution Layer: 입력 데이터에 필터를 적용 후 활성화 함수를 반영하는 필수 요소
    - Pooling Layer: 선택적인 레이어
      - Subsampling, downsampling 이라고도 부름



- **분류기**
  - CNN 마지막 부분에는 이미지 분류를 위한 Fully Connected 레이어가 추가
    - 처음은 Flatten 레이어
      - 이미지의 특징을 추출하는 부분과 이미지를 분류하는 부분 사이에 이미지 형태의 데이터를 배열 형태로 변환

# CNN 구조

- Feature Extraction + Classification



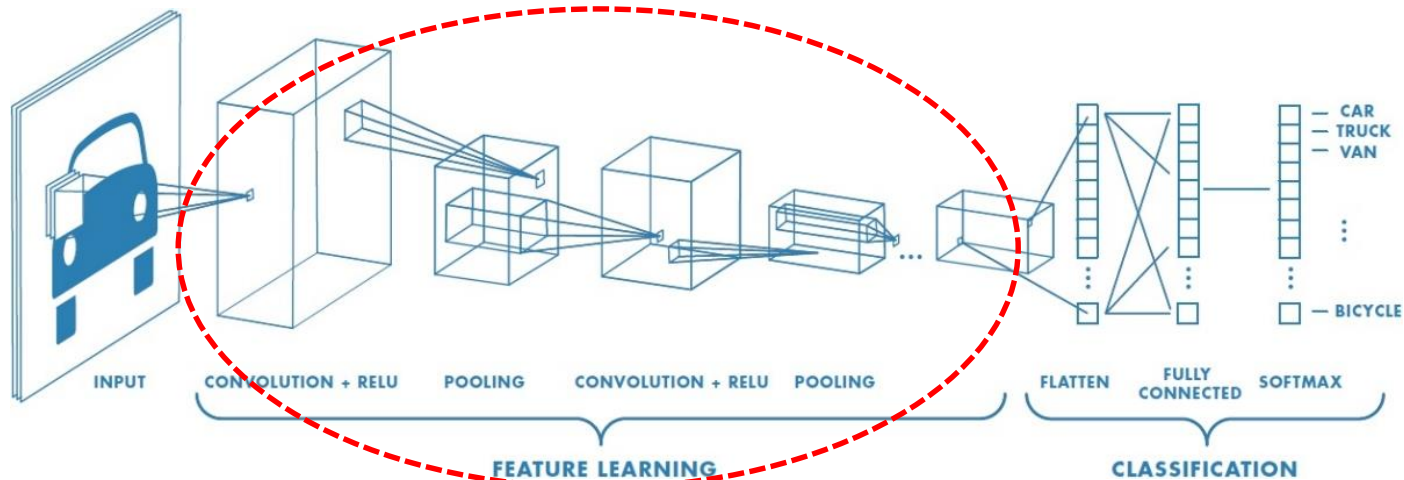
# CNN의 컨볼루션

## • 컨볼루션 층

- 각 이미지에서 특정 특징을 활성화하는 컨볼루션 필터 집합에 입력 이미지를 통과
- ReLU(Rectified Linear Unit)
  - 음수 값을 0에 매핑하고 양수 값을 유지하여 더 빠르고 효과적인 학습을 가능


## • 풀링(서브샘플링) 층

- 비선형 다운샘플링을 수행
  - 네트워크에서 학습해야 하는 매개 변수 수를 줄여서 출력을 간소화
    - 차원을 축소해 연산량을 감소
    - 이미지의 강한 특징만을 추출하는 특징 선별 효과가 있음



# CNN의 분류

- 여러 계층에서 특징을 학습한 다음 분류 단계로 이동
- K 차원의 벡터를 출력하는 완전 연결 계층
  - K는 네트워크가 예측할 수 있는 클래스의 수
    - 벡터에는 분류되는 이미지의 각 클래스에 대한 확률
  - 마지막 계층에서는 softmax와 같은 분류 계층을 사용하여 분류 출력을 제공



# 컨볼루션의 동기

- **이미지 위치에 따른 밀접한 상관관계**
  - 평판화(flatten) 작업을 수행하는 일반 딥러닝 구조
    - 이러한 공간적인 특성이 소멸
- **컨볼루션**
  - 데이터의 공간적인 특성이 유지




Figure 3: 3x3 흑백 이미지 예시

# 컨볼루션 계산 방법

## • 필터와 편향이 필요

- 4 x 4 흑백 이미지, 2 x 2 필터
  - 필터(filter), 커널(kernel), 윈도우(window)라고도 부름





Figure 7: Convolutional Layer 예제



$$(1 \times 2) + (2 \times 1) + (-1 \times 3) + (5 \times 2) = 11$$

Figure 8: Convolutional Layer 예제 (계속)

# 컨볼루션의 가중치와 편향

## • 딥러닝 관점

- 필터가 가중치, 필터 당 하나인 편향도 사용
  - 필터와 편향이 구해야 할 값





Figure 9: Convolutional Layer 예제 (계속)

컨볼루션 결과를 특성 맵(feature map)이라 부름



필터 4개와 편향 1개의 값을 구하기

Figure 10: Convolutional Layer with bias

# Convolution 합성곱

- 필터를 통해 합성곱의 결과인 피쳐 맵(또는 activation map)을 획득




그림3: 합성곱 계산 절차




그림1: 합성곱 처리 절차, 출처:

[http://deeplearning.stanford.edu/wiki/index.php/Feature\\_extraction\\_using\\_convolution](http://deeplearning.stanford.edu/wiki/index.php/Feature_extraction_using_convolution)



# Stride: 필터가 움직이는 간격

- 보폭 stride가 1로 필터를 입력 데이터에 순회하는 예제
  - stride가 2로 설정되면 필터는 2칸씩 이동하면서 합성곱을 계산
    - $4 \times 4$  가  $3 \times 3$  이 됨( $4 - 1[\text{strides}] = 3$ )

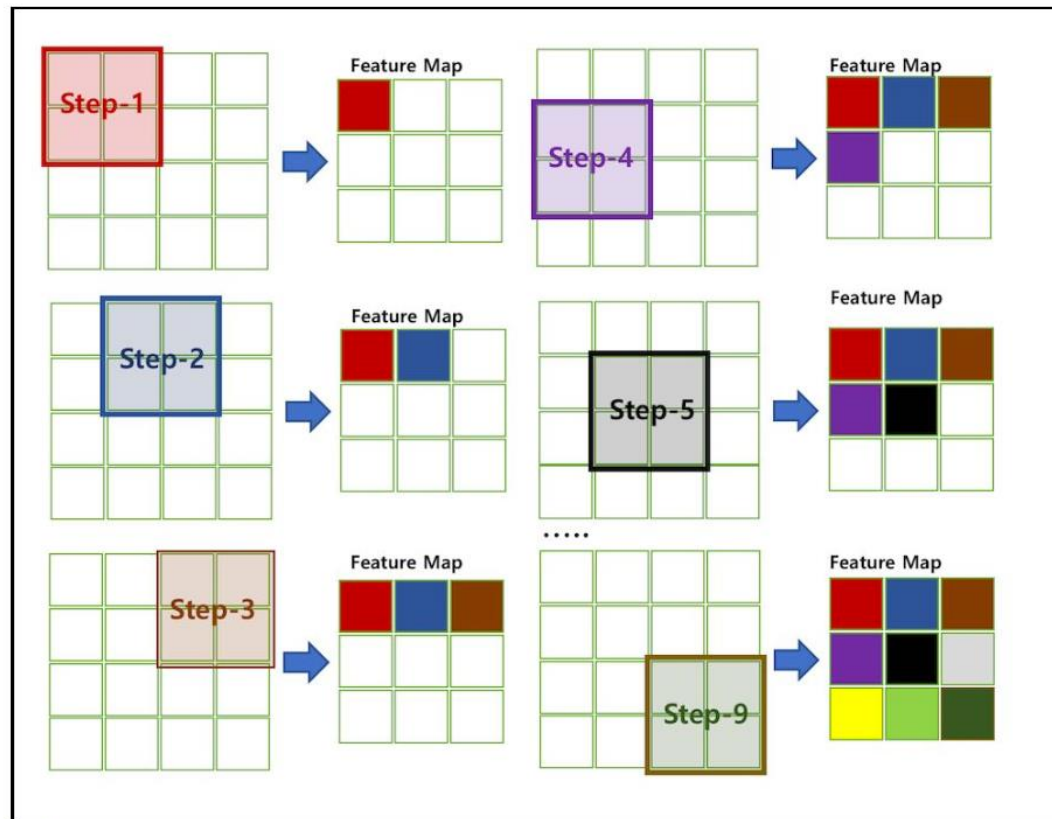



그림 4: Feature Map 과정

# 이미지 데이터

## 픽셀 단위로 구성

- 컬러인 경우, 각 픽셀은 RGB 값으로 구성
  - 이미지에서 겹쳐지는 부분을 채널(channel)이라고 하며
    - 흑백이면 1, 컬러면 3, RGBA(밝기인 alpha)이면 4



# 칼라인 경우, 채널이 3개

## • 입력 데이터가 여러 채널을 갖을 경우

- 필터는 채널마다 달리 적용
  - 필터는 각 채널을 순회하며 합성곱을 계산한 후, 채널별 피쳐 맵을 만들
- 1개의 피쳐 맵이 생성
  - 각 채널의 피쳐 맵을 합산하여 최종 피쳐 맵으로 반환
  - 입력 데이터는 채널 수와 상관없이 필터 별로 1개의 피쳐 맵이 생성





그림 5: 멀티 채널 입력 데이터에 필터를 적용한 합성곱 계산 절차

# Simple convolution layer

- Image: 1,3,3,1 image, Filter: 2,2,1,1, Stride: 1x1

(이미지 수, 가로, 세로, 채널)

(가로, 세로, 채널, 필터 수)



# 패딩(Padding)

## • 합성곱의 결과인 특징 맵

- Filter와 Stride에 작용으로 Feature Map 크기는 입력 데이터보다 작음

## • 패딩

- 입력 데이터 외각에 지정된 픽셀만큼 특정 값으로 채워 넣는 것 의미
  - 결과인 특징 맵 크기가 줄어드는 것을 방지하는 방법
- 보통 패딩 값으로 0으로 채워 넣음


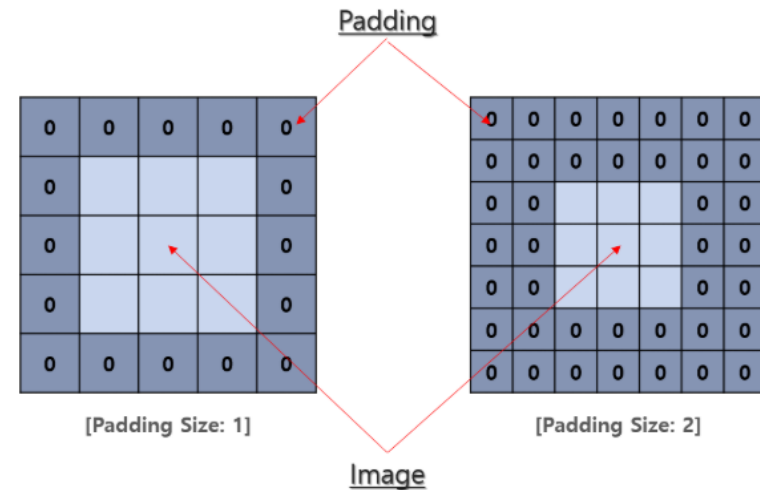


그림 6: padding 예제: 2pixel 추가

# Pooling 레이어

- 데이터의 공간적인 특성을 유지하면서 크기를 줄여주는 층
  - 컨볼루션의 결과를 줄이거나 특정 데이터를 강조
    - 연속적인 합성곱 층 사이에 삽입
  - 출력 데이터를 입력으로 받아서 출력 데이터(Activation Map)의 크기를 줄이거나 특정 데이터를 강조하는 용도로 사용
    - 학습할 가중치를 줄이고, 과적합(overfitting) 문제도 해결
  - 일반적으로 Pooling 크기와 Stride를 같은 크기로 설정하여 모든 원소가 한 번씩 처리 되도록 설정
- 풀링의 종류
  - Max Pooling
    - 정사각 행렬의 특정 영역 안에 값의 최댓값
    - 대부분 이것을 사용
  - Average Pooling, Min Pooling





그림 7: Pooling 예제: Max Pooling, Average Pooling

# Convolution layer and max pooling



Single depth slice

x ↑	1	1	2	4
	5	6	7	8
	3	2	1	0
	1	2	3	4
	y →			

max pool with 2x2 filters  
and stride 2


6	8
3	4

CNN(합성곱) 개요  
채널수, 필터수  
편향, 특징맵



# 하나의 이미지에 커널은 여러 개 구성 가능

- 32개의 필터 사용
  - 32개의 특징 맵이 생성



# 필터 4개

## • 컬러 색상에서 합성 곱 연산

- 필터 수 4개
  - $2 \times 2 \times 3$ (채널 수)
- 특징 맵이 4개





Figure 16: 필터 개수가 2이상인 합성

# 채널 수 3, 필터 수 2

- 채널 3
  - 커널 크기  $3 \times 3$
- 특징 맵의 결과
  - $4 \times 4$ 가 2개
    - $4 \times 4 \times 2$

<https://www.deeplearning.ai/>


Multiple filters



# 각 컨볼루션 단계의 패러미터 수

## • 패러미터의 수: 커널의 원소 수 + 편향 수

- 커널 수(K) \* 커널 사이즈(F)<sup>2</sup> \* 채널(색상 수(D)) + 커널 수(K)
- 컬러(채널 3), 커널 5 \* 5의 3개인 층에서의 패러미터 수
  - $3 * (5*5) * 3 + 3$
- 컬러(채널 3), 커널 5 \* 5의 6개인 층에서의 패러미터 수
  - $6 * (5*5) * 3 + 6$



# 유명 강의

- 스탠포드 대학의 CNN 강좌
  - CS231n 강의노트 Convolutional Neural Networks
    - <http://aikorea.org/cs231n/convolutional-networks/>
  - 강의 PPT
    - <http://cs231n.stanford.edu/slides/2020/>

# 컨볼루션 데모

## 컨볼루션 레이어


- 행렬(볼륨)의 구성
  - 입력 볼륨(파란색)
  - 가중치 볼륨(빨간색)
  - 출력 볼륨(녹색)

## 입력

- W1=5, H1=5
- D1=3(채널 수)
  - 제로 패딩 P=1 이 적용되어 입력 볼륨의 가장자리가 모두 0으로 추가

## 가중치(필터, 커널)

- 컨볼루션 레이어의 패러미터
- 3 \* 3 크기의 필터 수 2개
  - 편향도 2개
  - stride 2마다 적용
  - K=2, F=3, S=2, P=1



# 컨볼루션 데모

## • 입력

- W1=5, H1=5
- D1=3(채널 수)
  - 제로 패딩 P=1 이 적용되어 입력 볼륨의 가장자리가 모두 0으로 추가

## • 가중치(필터, 커널)

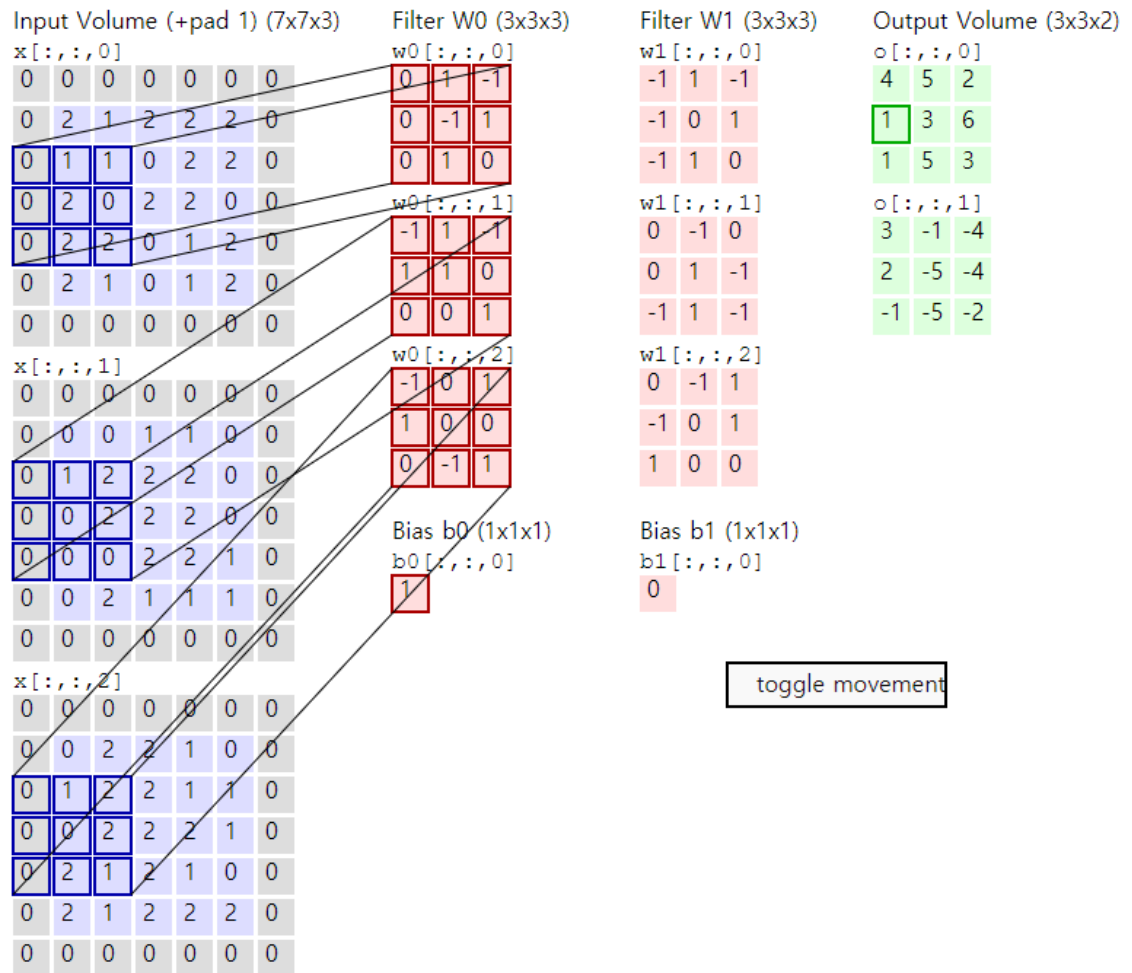
- 컨볼루션 레이어의 파라미터
- 3 \* 3 크기의 필터 수 2개
  - 편향도 2개
  - stride 2마다 적용
  - K=2, F=3, S=2, P=1

## • 출력 볼륨

- 크기와 계산
  - 가로/세로 각각  $(5 - 3 + 2)/2 + 1 = 3$
  - 입력(파란색)과 필터(빨간색)이 elementwise로 곱해진 뒤 하나로 더해지고
    - Bias가 더해짐
    - 필터 개수만큼 편향 수 필요

## • 파라미터의 수: 커널의 원소 수 + 편향 수

- 커널 수(K) \* 커널 사이즈(F)<sup>2</sup> \* 채널:색상 수(D) + 커널 수(K)



# CNN(합성곱) 실습



## 실습 소스 파일

- 12W-cnn-basic.ipynb

# 채널을 추가한 이미지 그리기

## • 3 x 3 이미지 하나

– (1, 3, 3)

## • 채널 추가

– (1, 3, 3, 1)

```
[1] 1 # %matplotlib inline
     2 import numpy as np
     3 import tensorflow as tf
     4 import matplotlib.pyplot as plt
```

```
1 image = np.array([[1,2,3],
2                   [4,5,6],
3                   [7,8,9]], dtype=np.float32)
4 print(image.shape)
5 image = image.reshape(-1, 3, 3, 1)
6 ...
7 image = np.array([[[[1],[2],[3]],
8                   [[4],[5],[6]],
9                   [[7],[8],[9]]]], dtype=np.float32)
10 ...
11 print(image.shape)
12 print(image)
13 plt.imshow(image.reshape(3,3), cmap='Greys')
```


그림을 그리기 위해 2차원으로

```
(1, 3, 3)
(1, 3, 3, 1)
[[[1.]
  [2.]
  [3.]

  [4.]
  [5.]
  [6.]

  [7.]
  [8.]
  [9.]]]]
```

<matplotlib.image.AxesImage at 0x7f26f3b1aef0>




# 채널을 추가된 이미지 그리기

- 4차원의 이미지
  - (1, 3, 3, 1)

```
[3] 1 image = np.array([[[[1],[2],[3]],
2                      [[4],[5],[6]],
3                      [[7],[8],[9]]]], dtype=np.float32)
4 print(image.shape)
5 plt.imshow(image.reshape(3,3), cmap='Greys')
```

```
↳ (1, 3, 3, 1)
<matplotlib.image.AxesImage at 0x7f9001b1dba8>
```




# 1 filter (2,2,1,1) with padding: VALID

weight.shape = 1 filter (2, 2, 1, 1)

## Simple convolution layer

Image: 1,3,3,1 image, Filter: 2,2,1,1, Stride: 1x1, Padding: VALID  
 이미지 수, 가로, 세로, 채널      가로, 세로, 채널, 필터 수      패딩 사용 안 하도록 지정



1, 2, 2, 1 = 채널, 가로, 세로, 특징 수

# tf.nn.conv2d

## • tf.nn.conv2d(input, filters, strides, padding, ...)

### – Strides

- [1, 가로이동, 세로이동, 1]

```
image = np.array([[[[1],[2],[3]],
                    [[4],[5],[6]],
                    [[7],[8],[9]]]], dtype=np.float32)
print("image.shape", image.shape)
```

# weight가 커널

```
weight = tf.constant([[[[1.]], [[1.]]],
                      [[[1.]], [[1.]]]])
print("weight.shape", weight.shape)
```

커널

```
conv2d = tf.nn.conv2d(image, weight, strides=[1, 1, 1, 1],
                      padding='VALID')
print("conv2d.shape", conv2d.shape)
```


```
conv2d_img = np.swapaxes(conv2d, 0, 3)
print(type(conv2d_img))
print(conv2d_img)
```

1, 2, 2, 1 = 채널, 가로, 세로, 특징 수  
채널과 특징을 교환하여 그림을 그리도록 하기 위해

```
for i, one_img in enumerate(conv2d_img):
    print(one_img.reshape(2,2))
    plt.subplot(1, 1, i+1)
    plt.imshow(one_img.reshape(2,2), cmap='gray')
```

```
image.shape (1, 3, 3, 1)
weight.shape (2, 2, 1, 1)
conv2d.shape (1, 2, 2, 1)
<class 'numpy.ndarray'>
[[[12.]
  [16.]
  [24.]
  [28.]]]
```


```
[[24.]
 [28.]]
[[12. 16.]
 [24. 28.]]
```



# 2 x 2 커널 2개 적용

## • Strides 1

– 결과 4 x 4



```
[[10. 10. 6. 6.]
 [12. 15. 13. 13.]
 [ 7. 11. 16. 7.]
 [10. 7. 4. 7.]]
```

$$= 2*2 + 1*3 + 1*0 + 3*1 = 10$$

$$= 2*.1 + 2*.2 + 0*.3 + 0*.4 = .6$$

```
[[1.9 2.2 1.6 2. ]
 [1.4 2.2 2.7 1.7 ]
 [1.7 1.3000001 1.3 1. ]
 [0.6 1.4000001 1.5 1.4 ]]
```

# 2 x 2 커널 2개 적용 컨볼루션

```
x_in = np.array([[
    [[2], [1], [2], [0], [1]],
    [[1], [3], [2], [2], [3]],
    [[1], [1], [3], [3], [0]],
    [[2], [2], [0], [1], [1]],
    [[0], [0], [3], [1], [2]], ]])
x = tf.constant(x_in, dtype=tf.float32)

# 2 x 2 커널 2개 적용
kernel_in = np.array([
    [[2, 0.1]], [[3, 0.2]] ],
    [[0, 0.3]], [[1, 0.4]] ], ])
kernel = tf.constant(kernel_in, dtype=tf.float32)

conv2d = tf.nn.conv2d(x, kernel, strides=[1, 1, 1, 1], padding='VALID')
print("conv2d.shape", conv2d.shape)



conv2d_img = np.swapaxes(conv2d, 0, 3)
for i, one_img in enumerate(conv2d_img):
    print(one_img.reshape(4,4))
    plt.subplot(1,2,i+1), plt.imshow(one_img.reshape(4,4), cmap='gray')
```



```
conv2d.shape (1, 4, 4, 2)
```

```
[[10. 10.  6.  6.]
 [12. 15. 13. 13.]
 [ 7. 11. 16.  7.]
 [10.  7.  4.  7.]]
```

```
[[1.9      2.2      1.6      2.      ]
 [1.4      2.2      2.7      1.7      ]
 [1.7      1.3000001 1.3      1.      ]
 [0.6      1.4000001 1.5      1.4      ]]
```

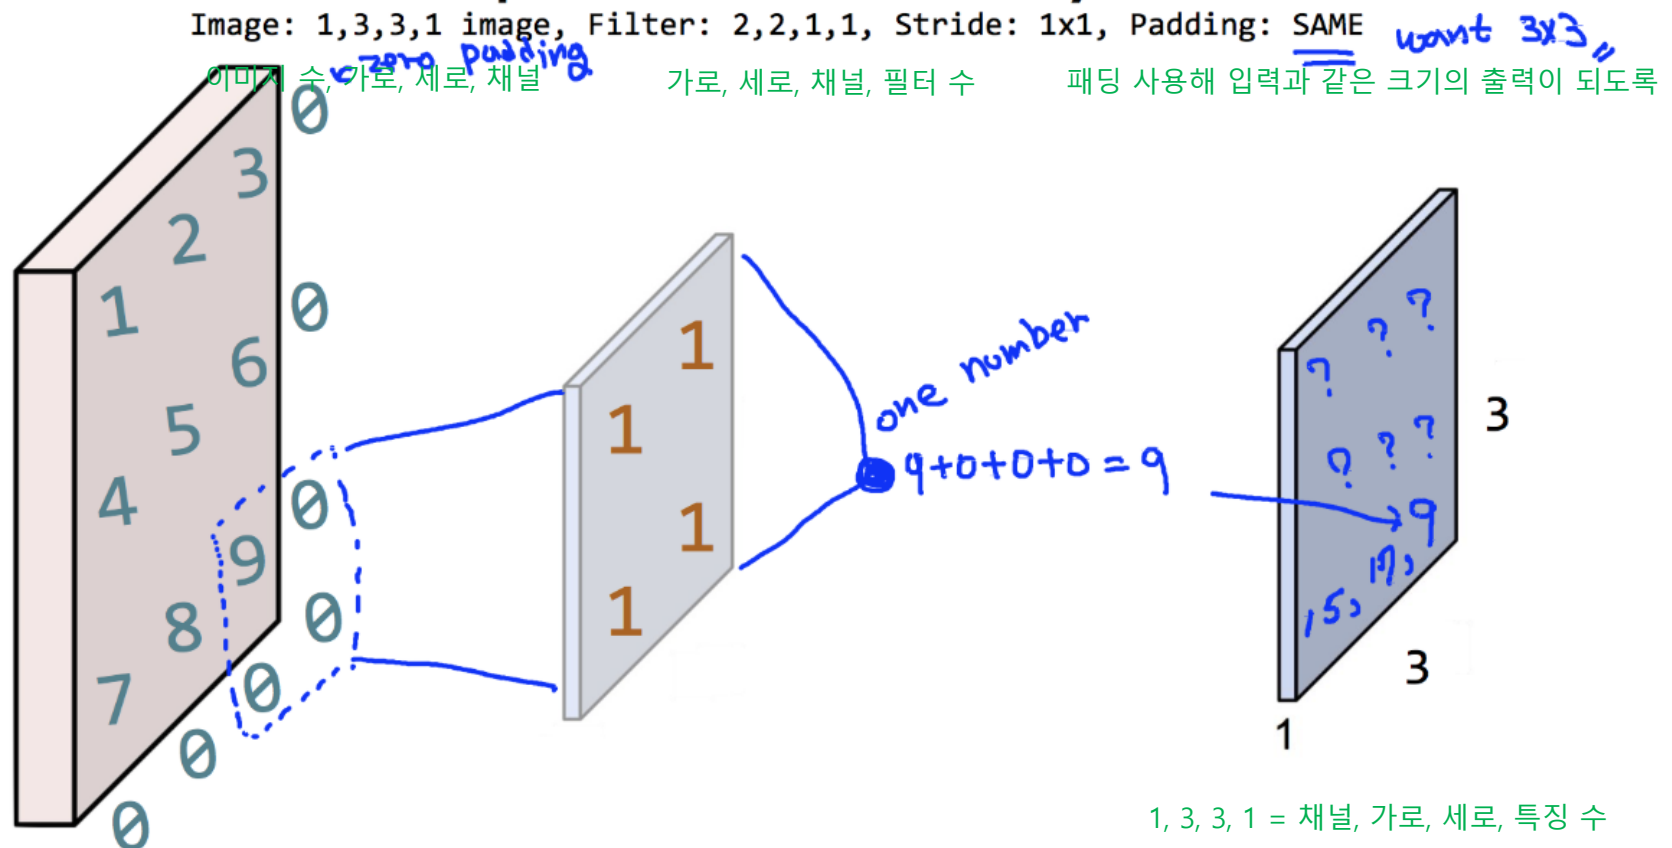


(1, 4, 4, 2) = 채널, 가로, 세로, 특징 수  
채널과 특징을 교환하여 그림을 그리도록 하기 위해

# tf.nn.conv2d(..., padding='SAME')

1 filter (2,2,1,1) with padding:SAME

## Simple convolution layer






# 컨볼루션 결과 크기도 원본과 동일

```
[7] 1 print("image.shape", image.shape)
    2
    3 weight = tf.constant([[[[1.]], [[1.]]],
    4                       [[[1.]], [[1.]]]])
    5 print("weight.shape", weight.shape)
    6
    7 conv2d = tf.nn.conv2d(image, weight, strides=[1, 1, 1, 1], padding='SAME')
    8 print("conv2d.shape", conv2d.shape)
    9
   10 conv2d_img = np.swapaxes(conv2d, 0, 3)
   11 for i, one_img in enumerate(conv2d_img):
   12     print(one_img.reshape(3,3))
   13     plt.subplot(1,2,i+1), plt.imshow(one_img.reshape(3,3), cmap='gray')
```


```
↳ image.shape (1, 3, 3, 1)
   weight.shape (2, 2, 1, 1)
   conv2d.shape (1, 3, 3, 1)
   [[12. 16.  9.]
    [24. 28. 15.]
    [15. 17.  9.]
```



# 필터 3개 사용, 필터 구조 = (2, 2, 1, 3)

```
1 image = np.array([[[[1],[2],[3]],
2                   [[4],[5],[6]],
3                   [[7],[8],[9]]]], dtype=np.float32)
4 print(image.shape)
5 plt.imshow(image.reshape(3,3), cmap='Greys')
```

```
(1, 3, 3, 1)
<matplotlib.image.AxesImage at 0x7f9001b1dba8>
```



1	1
1	1

```
[[12. 16. 9.]
 [24. 28. 15.]
 [15. 17. 9.]]
```

10	10
10	10

```
[[120. 160. 90.]
 [240. 280. 150.]
 [150. 170. 90.]]
```

-1	-1
-1	-1

```
[[ -12.  -16.  -9.]
 [-24.  -28. -15.]
 [-15.  -17.  -9.]]
```

```
weight = tf.constant([[[[1., 10., -1.]], [[1., 10., -1.]]],
                      [[[1., 10., -1.]], [[1., 10., -1.]]]])
```

(2,2,1,3)


가로, 세로, 채널, 필터 수

# 2행 2열의 채널 1개, 3개 filters (2,2,1,3)

가로, 세로, 채널, 필터 수

```
[8] 1 # print("imag:\n", image)
2 print("image.shape", image.shape)
3
4 weight = tf.constant([[[[1.,10.,-1.],[[1.,10.,-1.]]],
5                       [[[1.,10.,-1.],[[1.,10.,-1.]]]]])
6 print("weight.shape", weight.shape)
7
8 conv2d = tf.nn.conv2d(image, weight, strides=[1, 1, 1, 1], padding='SAME')
9 print("conv2d.shape", conv2d.shape)
10
11 conv2d_img = np.swapaxes(conv2d, 0, 3)
12 for i, one_img in enumerate(conv2d_img):
13     print(one_img.reshape(3,3))
14     plt.subplot(1,3,i+1), plt.imshow(one_img.reshape(3,3), cmap='gray')
```


↳ image.shape (1, 3, 3, 1)  
 weight.shape (2, 2, 1, 3)  
 conv2d.shape (1, 3, 3, 3)  
 [[12. 16. 9.]  
 [24. 28. 15.]  
 [15. 17. 9.]  
 [[120. 160. 90.]  
 [240. 280. 150.]  
 [150. 170. 90.]  
 [[-12. -16. -9.]  
 [-24. -28. -15.]  
 [-15. -17. -9.]



# 커널 2, 스트라이드 2, 이미지 크기 2 x 2의 맥스풀링

- padding='VALID'

## MAX POOLING



```


1 image = np.array([[[[4],[3]],
2                   [[2],[1]]]], dtype=np.float32)
3 pool = tf.nn.max_pool(image, ksize=[1, 2, 2, 1],
4                       strides=[1, 1, 1, 1], padding='VALID')
5 print(pool.shape)
6 print(pool.numpy())

```

```

(1, 1, 1, 1)
[[[4.]]]


```



# 옵션 padding

- padding='SAME'

▼ SAME: Zero paddings



```
[10] 1 image = np.array([[[[4],[3]],
2           [[2],[1]]]], dtype=np.float32)
3 pool = tf.nn.max_pool(image, ksize=[1, 2, 2, 1],
4           strides=[1, 1, 1, 1], padding='SAME')
5 print(pool.shape)
6 print(pool.numpy())
```

```
↳ (1, 2, 2, 1)
   [[[4.]
    [3.]]
   [[2.]
    [1.]]]]
```


# 학습 데이터

- 첫 이미지
  - mnist[0][0][0]:
    - 학습 데이터, 이미지 중, 첫번째

```
[11] 1 import tensorflow as tf
      2 mnist = tf.keras.datasets.mnist
      3
      4 mnist = mnist.load_data()
```


```
[12] 1 img = mnist[0][0][0].reshape(28,28)
      2 plt.imshow(img, cmap='gray')
      3 print(img.shape)
```

↳ (28, 28)



# 필터 크기 3, strides 2


- 필터 사이즈:  $k$ 
  - 사방으로  $k/2$  만큼의 패딩
  - $K=3$ 
    - $3/2 = 1$
- Strides 2인 경우
  - 결과
    - $14 \times 14$ 
      - $(30 - 3) / 2 + 1$
      - $(\text{총길이}-\text{필터 크기})/\text{strides} + 1$



# 필터 크기가 3이고 **strides 2**, 필터 수가 5

```
[13] 1 # 4차원으로 확장
      2 img = img.reshape(-1,28,28,1)
      3 # 3 x 3의 필터 5개 생성
      4 W1 = tf.Variable(tf.random.normal([3, 3, 1, 5], stddev=0.01))
      5
      6 conv2d = tf.nn.conv2d(img, W1, strides=[1, 2, 2, 1], padding='SAME')
      7 print(conv2d.shape)
      8
      9 conv2d_img = np.swapaxes(conv2d, 0, 3)
     10 for i, one_img in enumerate(conv2d_img):
     11     plt.subplot(1,5,i+1)
     12     plt.imshow(one_img.reshape(14,14), cmap='gray')
     13
```

↳ (1, 14, 14, 5)






# 다시 맥스풀링 적용


- 필터 크기가 2이고 strides 2 적용
  - 이미지의 크기가 반으로 줄

↳ (1, 14, 14, 5)



```
[15] 1 pool = tf.nn.max_pool(conv2d, ksize=[1, 2, 2, 1],
2                                strides=[1, 2, 2, 1], padding='SAME')
3 print(pool.shape)
4
5 pool_img = np.swapaxes(pool, 0, 3)
6 for i, one_img in enumerate(pool_img):
7     plt.subplot(1,5,i+1)
8     plt.imshow(one_img.reshape(7, 7), cmap='gray')
```

↳ (1, 7, 7, 5)



# 이미지를 위한 `keras.layers.Conv2D`

- `keras.layers.Conv2D()`

- `filters`, `kernel_size`, `strides=(1, 1)`, `padding='valid'`, `data_format=None`, `activation=None`, `use_bias=True`, ...

- **주요 인자**

- `filters`: 정수, 컨볼루션의 출력 필터의 수
- `kernel_size`: 정수 혹은 단일 정수의 튜플/리스트, 커널 크기(가로, 세로)
- `strides`: 정수 혹은 단일 정수의 튜플/리스트. 컨볼루션의 보폭 길이를 특정
- `padding`: "valid", 혹은 "same" (대소문자 무시). "valid"는 "패딩 없음"을 의미
  - "same"은 아웃풋이 원래 인풋과 동일한 길이를 갖도록 인풋을 패딩
  - 제로 패딩을 사용해 아웃풋이 원래의 인풋과 같은 길이를 갖도록
- `data_format`: 문자열, "channels\_last" (디폴트 값) 혹은 "channels\_first" 중 하나
  - **입력 차원의 순서를 표현**
    - "channels\_last"는 (이미지수, 높이, 너비, channels) 형태
    - "channels\_first"는 (이미지수, channels, 높이, 너비) 형태

- **입력 형태**

- `data_format`이 "channels\_last"이면 (batch, rows, cols, channels) 형태의 4D 텐서
  - `data_format`이 "channels\_first"이면 (batch, channels, rows, cols) 4D 텐서

- **출력 형태**

- `data_format`이 "channels\_last"이면 (batch, new\_rows, new\_cols, filters) 형태의 4D 텐서
  - `data_format`이 "channels\_first"이면 (batch, filters, new\_rows, new\_cols) 4D 텐서

# MNIST 입력 모양

- 흑백 이미지, 60000개  $28 \times 28$ , 기본 형태, 채널 라스트
  - (60000, 28, 28, 1)

